

状態空間モデルを用いた 日本国内のトラック輸送量における時系列分析

寺嶋風雅*

要 旨

本研究は、状態空間モデルを用いて、日本国内の宅配便取扱個数の月次データ（2002年4月～2022年7月）における変動要因の分離と定量化を行った。先行研究ではSARIMAモデルが用いられたが、運賃値上げやコロナ禍のパンデミックといった外部イベントが需要に与えたインパクトを数値として分離・評価するには限界があった。そこで本研究では、ローカル線形トレンドと季節性に加え、2017年の運賃値上げと新型コロナウイルス感染症（COVID-19）のパンデミックを外部イベントとして考慮した、複数の状態空間モデルを構築した。

客観的指標であるAICを用いたモデル比較の結果、コロナ禍の影響を複数のフェーズ（構造変化、第一波、2021年の波）に分けて固定係数でモデル化した「フェーズ分けモデル」が最も優れたモデルとして採択された。本研究は、状態空間モデルの柔軟性を活用することで、複雑な時系列データに潜む複数のイベント効果を、その性質に応じて適切に分離・評価できることを実証した。これにより、物流業界の動向をより正確に把握し、将来の予測や政策決定に資することが期待される。

1. はじめに

近年、日本の物流業界はEコマース市場の拡大に伴い、その重要性を増している。一方で、『ラストワンマイル問題』に代表される労働力不足や、燃料費の高騰といった多くの課題に直面しており、物流の効率化と持続可能性の向上は喫緊の社会課題となっている。こうした背景から、物流の動向を正確に把握し、その変動要因を理解することは、事業者および政策決定者にとって極めて重要である。物流動向を把握する一つのアプローチとして、時系列解析が有効である。この点に関して、赤羽根(2024)による先行研究は、国土交通省の統計から20年分の宅配便取扱個数の月次データを構築し、SARIMAモデルを用いてその基本構造を分析した。この研究は、運賃値上げなどのイベントがトレンドに影響を与えた可能性を示唆するなど、重要な貢献をなした。しかし、先行研究で用いられたSARIMAモデルでは、運賃値上げや、その後に発生した新型コロナウイルスのパンデミックといった外部イベントが、需要に具体的にどれほどの量的インパクトを与えたのかを、他の要因から分離して評価することは困難であった。そこで本研究では、この課題を克服するため、状態空間モデルを適用する。これにより、トレンドや季節性といった基本成分に加え、複数の外部イベントが与えた影響を、その性質に応じて統計的に分離・

*中央大学大学院 理工学研究科, Email: a21.gn8t@g.chuo-u.ac.jp

定量化することを目的とする．本研究で使⽤したデータの原系列を図 1 に示す．




図 1: 宅配便取扱個数の原系列

2. 分析手法

2.1 使⽤データ

本研究で使⽤するデータは，国土交通省が公表する「交通関係統計資料」から取得した2002年4月から2022年7月までの月次データである．先行研究（赤羽根, 2024）において構築されたデータセットを利⽤した．主要な変数と宅配便取扱個数の現系列を表1に示す．

表 1: 主要変数一覧

カラム名	内容
label	年月 (YYYY-MM-DD)
year	年
month	月
Transport_tonnage	輸送トン数 (トン)
number_parcel	宅配便取扱個数 (千個)
Number_companies_1	輸送トン数の調査会社数 (社)
Number_companies_2	宅配便取扱個数の調査会社数 (社)

変動を安定させるため，本分析の目的変数には，number_parcelの自然対数を取った値を利⽤した．

2.2 分析モデル

本研究で利⽤した状態空間モデルは，以下のシステムモデルおよび観測モデルによって表現される．

$$x_t = F_t x_{t-1} + G_t \eta_t \quad (2.1)$$

$$y_t = H_t x_t + \beta d_t + \epsilon_t \quad (2.2)$$

ここで， x_t は状態ベクトル， y_t は観測値を表す．状態攪乱項 η_t および観測攪乱項 ϵ_t は，それぞれ以下の正規分布に従うと仮定する．

$$\begin{bmatrix} \eta_{\mu_t} \\ \eta_{\gamma_t} \end{bmatrix} \sim N \left(0, \begin{bmatrix} \sigma_{\mu_t}^2 & 0 \\ 0 & \sigma_{\gamma_t}^2 \end{bmatrix} \right) \quad (2.3)$$

$$\epsilon_t \sim N(0, \sigma_{\epsilon_t}^2) \quad (2.4)$$

ここで，状態ベクトル x_t は，トレンド成分と周期12の季節成分から構成される．具体的には，状態ベクトル x_t ，遷移行列 F_t ，観測ベクトル H_t は，それぞれ以下のように定義される．

$$x_t = \begin{bmatrix} \mu_t \\ \delta_t \\ \gamma_t \\ \gamma_{t-1} \\ \vdots \\ \gamma_{t-10} \end{bmatrix}, \quad (2.5)$$

$$F_t = \begin{bmatrix} 1 & 1 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & -1 & \dots & -1 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{bmatrix}, \quad (2.6)$$

$$H_t = \begin{bmatrix} 1 & 0 & 1 & 0 & \dots & 0 \end{bmatrix} \quad (2.7)$$

2.3 外生変数の設計

本研究で利⽤する状態空間モデルは，トレンドや季節性といった内部構造に加え，外部からのイベントが時系列に与える影響を分離して分析できる

点が特徴である。ここでは、観測方程式に組み込む外生変数 d_t の具体的な設計について述べる。

宅配便の取扱個数は、社会・経済情勢の変化に敏感に反応すると考えられる。特に、分析対象期間中には、業界全体に影響を及ぼした大規模な運賃値上げと、人々の生活様式を大きく変容させた新型コロナウイルス感染症（COVID-19）のパンデミックという2つの重要なイベントが発生した。これらの影響を適切にモデル化するため、本研究ではイベントの性質に応じて期間を設定したダミー変数を設計し、外生変数として導入する。各ダミー変数は、イベントが発生している期間は1、それ以外の期間は0をとるバイナリ変数である。モデルは、これらの変数に対する係数 β を推定することで、各イベントが宅配便取扱個数に与えた瞬間的なインパクトの大きさを定量的に評価する。具体的な変数設計はに示す通りである。...前置きの文章... 本モデルで外生変数として導入するダミー変数は以下の通りである。

- **hike_dummy**: 2017年10月に実施された主要各社の運賃値上げの影響を捉えるための変数。（対象期間: 2017/10 – 2019/12）
- **covid_main**: COVID-19パンデミックによる巣ごもり需要の定着など、市場構造そのものに与えた持続的な変化（構造変化）を捉える変数。（対象期間: 2020/03 – ）
- **covid_wave1**: 緊急事態宣言下での急激な需要増など、パンデミック初期の短期的なインパクトを捉える変数。（対象期間: 2020/04 – 2020/05）
- **covid_2021**: 感染再拡大に伴う断続的な需要増の影響を捉える変数。（対象期間: 2021/01 – 2021/09）

2.4 比較モデル

本研究で採用する最終モデルの優位性、および各外部イベントが与える影響の重要性を評価する

ため、以下の3つの状態空間モデルを構築し、比較検討を行った。各モデルは、2.2節で述べた基本構造を共有しつつ、2.3節で設計した外生変数の組み込み方が異なる。

- **ベースラインモデル**: ローカル線形トレンド成分と季節成分のみで構成されるモデル。外部イベントの影響を一切考慮しない、最も基本的なモデルであり、分析の基準点（ベンチマーク）となる。
- **単純イベントモデル**: ベースラインモデルに加え、運賃値上げダミーと、コロナ禍の影響を単一のダミー変数（covid_main）のみで表現したモデル。イベントの影響を単純化した形で評価する。
- **提案モデル**: ベースラインモデルに加え、運賃値上げダミーと、コロナ禍の影響をその性質に応じて複数のフェーズに分けたダミー変数群（covid_main, covid_wave1, covid_2021）を全て組み込んだ、本研究における提案モデルである。

これらの3モデルをそれぞれ推定し、モデルの当てはまりの良さを情報量規準AICによって評価した。その比較結果は次章で詳述する。

3. 分析結果

3.1 モデルの比較と選択

表 2: モデルの比較

モデル	対数尤度	AIC	BIC
1. ベースラインモデル	471.9	-913.9	-861.4
2. 単純イベントモデル	477.5	-915.0	-855.1
3. 提案モデル	480.9	-919.9	-846.4

3.2 提案モデルの推定結果

提案モデルのパラメータ推定結果を表3に示す。なお、各モデルのパラメータ推定にあたっては初

期値依存を避け安定した解を得るため、複数の初期値候補によるグリッドサーチによって最尤解を探索した。

表 3: 提案モデルのパラメータ推定結果

パラメータ	推定値 (coef)	標準誤差 (std err)	p値 ($P > z $)
外生変数効果			
hike_effect	-0.023	0.031	0.464
covid_main_effect	0.049	0.040	0.222
covid_wave1_effect	0.045	0.026	0.077
covid_2021_effect	0.020	0.015	0.184
分散パラメータ			
観測ノイズ (σ_ϵ^2)	0.0003	4.35e-05	0.000
トレンドノイズ (σ_μ^2)	8.66e-05	2.29e-05	0.000
傾きノイズ (σ_δ^2)	2.46e-11	2.61e-08	0.999
季節ノイズ (σ_γ^2)	5.30e-05	1.63e-05	0.001

表 3 から、コロナ禍第一波の効果 (covid_wave1_effect) の係数が約 0.045 であり、10%水準で統計的に有意であったことが確認できる ($p=0.077$)。これは、最初の緊急事態宣言下において、他の要因に加えて約4.5%の追加的な需要増があったことを示唆している。

3.3 時系列の成分分解

提案モデルによる分解結果を 2 に示す。




図 2: 提案モデルによる時系列成分の分解

図2上段の観測値とフィット値の比較から、モデルが実際のデータの変動を非常によく捉えていることがわかる。中段のトレンド成分は、分析期間を通して一貫した上昇傾向にあるが、2008年や2014年付近で一時的な成長の鈍化が見られる。下段の季節成分は、毎年夏に減少し冬に増加する、安定した周期変動を示している。上段の外部イベント効果を見ると、コロナ禍第一波の期間に、他のイベントよりも顕著な正のインパクトが瞬間的に発生していることが視覚的に確認できる。下段の残差は、全体として特定のパターンを持たないランダムな変動となっており、モデルがデータの主要な構造を十分に捉えられていることを示唆している。

4. 考察

(ここに結果が何を意味するのかを解釈します.
「コロナ第一波のインパクトはなぜ突出していたか」など, 私たちの議論を文章化します.)

5. おわりに

(ここに研究全体の結論と, 今後の展望を記述します.)

謝 辞

本研究の基盤となる時系列データの構築にあたり, 機械学習研究室の赤羽根悠悟氏 (2024年度卒業) が作成されたデータを活用させていただきました. ここに記して, 深く感謝の意を表します.

参考文献

Structural Change Analysis of Parcel Delivery Volume in Japan Using State-Space Models

Fuga Terashima*

* Graduate School of Science and Engineering, Chuo University

(ここに英語の要旨を記述します. 日本語要旨より少し詳しく書くのが一般的です.)

Key words: state-space model, structural change, time series analysis, COVID-19, logistics