

状態空間モデルを用いた日本国内 トラック輸送量の外部要因の定量的把握

寺嶋風雅* 赤羽根悠悟** 冬木拓実*** 樋口知之†

要 旨

本研究は、状態空間モデルを用いて、日本国内の宅配便取扱個数の月次データ（2002年4月～2022年7月）における変動要因の分離と定量化を国内で初めて行った。先行研究（赤羽根, 2024）では、SARIMA（Seasonal AutoRegressive Integrated Moving Average）モデルが採用された。SARIMAモデルは、ARIMAモデルに季節周期的な変動を取り入れた手法であり、過去のデータと誤差の相関構造を利用して高い予測精度を実現する。しかし、このモデルでは運賃値上げやコロナ禍のパンデミックといった外的要因が需要に与えたインパクトを数値として分離・評価するには限界があった。そこで本研究では、ローカル線形トレンドと季節性に加え、2017年における主要各社の宅配便運賃値上げと新型コロナウイルス感染症（COVID-19）のパンデミックを外部イベントとして考慮した複数の状態空間モデルを構築した。

客観的指標であるAICを用いたモデル比較の結果、コロナ禍の影響を複数のフェーズ（構造変化、第一波、2021年の波）に分けて固定係数でモデル化した「フェーズ分けモデル」が最も優れたモデルとして採択された。本研究は、状態空間モデルの柔軟性を活用することで、複雑な時系列データ

に潜む複数のイベント効果を、その性質に応じて適切に分離・評価できることを実証した。これにより、物流業界の動向をより正確に把握し、将来の予測や政策決定に資することが期待される。

1. はじめに

近年、日本の物流業界はEコマース市場の拡大に伴い、その重要性を増している。一方で、『ラストワンマイル問題』に代表される労働力不足や、燃料費の高騰といった多くの課題に直面しており、物流の効率化と持続可能性の向上は喫緊の社会課題となっている。こうした背景から、物流の動向を正確に把握し、その変動要因を理解することは、事業者および政策決定者にとって極めて重要である。物流動向を把握する一つのアプローチとして、時系列解析が有効である。この点に関して、赤羽根（2024）による先行研究は、国土交通省の統計から20年分の宅配便取扱個数の月次データを構築し、SARIMAモデルを用いてその基本構造を分析した。この研究は、運賃値上げなどのイベントがトレンドに影響を与えた可能性を示唆するなど、重要な貢献をなした。しかし、同研究ではイベントの外的要因の分離までは困難であり、今後の展望として状態空間モデルの適用を提案していた。本研究は、この先行研究の課題と提案を直接

*中央大学大学院 理工学研究科

**中央大学理工学部

***中央大学大学院 理工学研究科

†中央大学理工学部

引き継ぎ、状態空間モデルを適用することで、トレンドや季節性といった基本成分に加え、複数の外部イベントが与えた影響を、その性質に応じて統計的に分離・定量化することを目的とする。本研究で使用したデータの原系列を図 1 に示す。




図 1: 宅配便取扱個数の原系列

2. 分析手法

2.1 使用データ

本研究で使用するデータは、国土交通省が公表する「交通関係統計資料」から取得した2002年4月から2022年7月までの月次データである。先行研究（赤羽根, 2024）において構築されたデータセットを利用した。主要な変数と宅配便取扱個数の現系列を表1に示す。

表 1: 主要変数一覧

カラム名	内容
label	年月 (YYYY-MM-DD)
year	年
month	月
Transport_tonnage	輸送トン数 (トン)
number_parcel	宅配便取扱個数 (千個)
Number_companies_1	輸送トン数の調査会社数 (社)
Number_companies_2	宅配便取扱個数の調査会社数 (社)

変動を安定させるため、本分析の目的変数には、number_parcelの自然対数を取った値を用いた。

2.2 分析モデル

本研究で用いた状態空間モデルは、以下のシステムモデルおよび観測モデルによって表現される。

$$x_t = F_t x_{t-1} + G_t \eta_t \quad (2.1)$$

$$y_t = H_t x_t + \beta d_t + \epsilon_t \quad (2.2)$$

各攪乱項は、互いに独立な正規分布に従うと仮定する。

$$\eta_t = \begin{bmatrix} \eta_{\mu,t} \\ \eta_{\delta,t} \\ \eta_{\gamma,t} \end{bmatrix} \sim N \left(0, \begin{bmatrix} \sigma_{\mu}^2 & 0 & 0 \\ 0 & \sigma_{\delta}^2 & 0 \\ 0 & 0 & \sigma_{\gamma}^2 \end{bmatrix} \right) \quad (2.3)$$

$$\epsilon_t \sim N(0, \sigma_{\epsilon}^2) \quad (2.4)$$

ここで、状態ベクトル x_t は、トレンド成分と周期12の季節成分から構成される。具体的には、状態ベクトル x_t 、遷移行列 F_t 、観測ベクトル H_t は、それぞれ以下のように定義される。

$$x_t = \begin{bmatrix} \mu_t \\ \delta_t \\ \gamma_t \\ \gamma_{t-1} \\ \vdots \\ \gamma_{t-11} \end{bmatrix}, \quad (2.5)$$

$$F_t = \begin{bmatrix} 1 & 1 & 0 & \dots & \dots & 0 \\ 0 & 1 & 0 & \dots & \dots & 0 \\ 0 & 0 & -1 & \dots & \dots & -1 \\ 0 & 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & & \ddots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 & 0 \end{bmatrix}, \quad (2.6)$$

$$H_t = \begin{bmatrix} 1 & 0 & 1 & 0 & \dots & 0 \end{bmatrix} \quad (2.7)$$

ここで、 μ_t は t 時点のトレンドの水準、 δ_t はトレンドの傾きを表す。 γ_t は現在の季節効果を示し、遷移行列 F_t の3行目 ($-1, \dots, -1$) により、 $\sum_{j=0}^{11} \gamma_{t-j} = 0$ という制約が課される。モデルのパラメータ（分散 σ^2 群および係数 β 群）は、最尤法によって推定される。

観測方程式 (2.2) における外生変数項 βd_t は、運賃値上げおよびコロナ禍の各フェーズが与える影響の総和を表す。係数ベクトル β および ダミー変数ベクトル d_t は、具体的に以下のように定義される。

$$\beta = \begin{bmatrix} \beta_{\text{hike}} & \beta_{\text{covid_main}} & \beta_{\text{covid_wave1}} & \beta_{\text{covid_2021}} \end{bmatrix} \quad (2.8)$$

$$d_t = \begin{bmatrix} d_{\text{hike},t} & d_{\text{covid_main},t} & d_{\text{covid_wave1},t} & d_{\text{covid_2021},t} \end{bmatrix}^T \quad (2.9)$$

外生変数項はこれらの内積 βd_t として定義される。

2.3 外生変数の設計

本研究で用いる状態空間モデルは、トレンドや季節性といった内部構造に加え、外部からのイベントが時系列に与える影響を分離して分析できる点が特徴である。ここでは、観測方程式に組み込む外生変数 d_t の具体的な設計について述べる。

宅配便の取扱個数は、社会・経済情勢の変化に敏感に反応すると考えられる。特に、分析対象期間中には、業界全体に影響を及ぼした大規模な運賃値上げと、人々の生活様式を大きく変容させた新型コロナウイルス感染症 (COVID-19) のパンデミックという2つの重要なイベントが発生した。これらの影響を適切にモデル化するため、本研究ではイベントの性質に応じて期間を設定したダミー変数を設計し、外生変数として導入する。各ダミー変数は、イベントが発生している期間は1、それ以外の期間は0をとるバイナリ変数である。モデルは、これらの変数に対する係数 β を推定することで、各イベントが宅配便取扱個数に与えた瞬間的なインパクトの大きさを定量的に評価する。具体的な変数設計はに示す通りである。本モデルで外生変数として導入するダミー変数は以下の通りである。

- **hike_dummy**: 2017年10月に実施された主要各社の運賃値上げの影響を捉えるための変数。 (**対象期間: 2017/10 – 2019/12**) 主要3社 (ヤマト運輸, 佐川急便, 日本郵便) の値上げ実施時期から、コロナ禍の影響が顕在化する直前の期間までを設定した。
- **covid_main**: COVID-19パンデミックによる巣ごもり需要の定着など、市場構造そのものに与えた持続的な変化 (構造変化) を捉える変数。 (**対象期間: 2020/03 –**) WHOによるパンデミック宣言や国内での影響が本格化した時期から、分析期間の終わりまで持続するベースラインの上昇として設定した。
- **covid_wave1**: パンデミック初期の短期的なインパクトを捉える変数。 (**対象期間: 2020/04 – 2020/05**) 日本国内で最初の緊急事態宣言が発令された期間と一致させており、外出自粛に伴う一時的な特需を分離するために設定した。
- **covid_2021**: 感染再拡大に伴う断続的な需要増の影響を捉える変数。 (**対象期間: 2021/01 – 2021/09**) 2回目および3回目の緊急事態宣言が主要都市に断続的に発令されていた期間 (デルタ株の流行期) と概ね一致させて設定した。

2.4 比較モデル

本研究で採用する最終モデルの優位性、および各外部イベントが与える影響の重要性を評価するため、以下の3つの状態空間モデルを構築し、比較検討を行った。各モデルは、2.2節で述べた基本構造を共有しつつ、2.3節で設計した外生変数の組み込み方が異なる。

- **ベースラインモデル**: ローカル線形トレンド成分と季節成分のみで構成されるモデル。

外部イベントの影響を一切考慮しない、最も基本的なモデルであり、分析の基準点（ベンチマーク）となる。

- **単純イベントモデル**: ベースラインモデルに加え、運賃値上げダミーと、コロナ禍の影響を単一のダミー変数（covid_main）のみで表現したモデル。イベントの影響を単純化した形で評価する。
- **提案モデル**: ベースラインモデルに加え、運賃値上げダミーと、コロナ禍の影響をその性質に応じて複数のフェーズに分けたダミー変数群（covid_main, covid_wave1, covid_2021）を全て組み込んだ、本研究における提案モデルである。

これらの3モデルをそれぞれ推定し、モデルの当てはまりの良さを情報量規準AICによって評価した。その比較結果は次章で詳述する。

3. 分析結果

3.1 モデルの比較と選択

表 2: モデルの比較

モデル	対数尤度	AIC	BIC
1. ベースラインモデル	471.9	-913.9	-861.4
2. 単純イベントモデル	477.5	-915.0	-855.1
3. 提案モデル	480.9	-919.9	-846.4

なお、パラメータ数に対しより強いペナルティを課すBICでは、よりシンプルな『単純イベントモデル』が最良となった（表2）。しかし本研究では、コロナ禍のインパクトをその性質に応じて複数のフェーズに分離して解釈することの理論的な重要性を重視し、AICに基づき『提案モデル』を分析対象として採択した。

3.2 提案モデルの推定結果

提案モデルのパラメータ推定結果を表3に示す。なお、各モデルのパラメータ推定にあたっては初

期値依存を避け安定した解を得るため、複数の初期値候補によるグリッドサーチによって最尤解を探索した。

表 3: 提案モデルのパラメータ推定結果

パラメータ	推定値 (coef)	標準誤差 (std err)	p値 ($P > z $)
外生変数効果			
hike_effect	-0.023	0.031	0.464
covid_main_effect	0.049	0.040	0.222
covid_wave1_effect	0.045	0.026	0.077
covid_2021_effect	0.020	0.015	0.184
分散パラメータ			
観測ノイズ (σ_ϵ^2)	0.0003	4.35e-05	0.000
トレンドノイズ (σ_μ^2)	8.66e-05	2.29e-05	0.000
傾きノイズ (σ_δ^2)	2.46e-11	2.61e-08	0.999
季節ノイズ (σ_γ^2)	5.30e-05	1.63e-05	0.001

表 3 から、コロナ禍第一波の効果（covid_wave1_effect）の係数が約 0.045 であり、10%水準で統計的に有意であったことが確認できる（ $p=0.077$ ）。これは、最初の緊急事態宣言下において、他の要因に加えて約4.5%の追加的な需要増があったことを示唆している。一方で、2017年の運賃値上げ効果（hike_effect, $p=0.464$ ）や、コロナ禍による持続的な構造変化（covid_main_effect, $p=0.222$ ）、2021年の波（covid_2021_effect, $p=0.184$ ）については、本モデルでは統計的に有意な水準の変化としては検出されなかった。

3.3 時系列の成分分解

提案モデルによる分解結果を 2 に示す。




図 2: 提案モデルによる時系列成分の分解

図2上段の観測値とフィット値の比較から、モデルが実際のデータの変動を非常によく捉えていることがわかる。中段のトレンド成分は、分析期間を通して一貫した上昇傾向を示している。表3のパラメータ推定結果では、傾きノイズ (σ_θ^2) がほぼゼロ ($2.46\text{e-}11$) と推定されており、これはトレンドの成長率が分析期間を通じてほぼ一定であったことを示唆している。したがって、図2のトレンド成分に見られる2008年頃の変動は、成長率そのものの鈍化ではなく、水準に対するショック (トレンドノイズ σ_μ^2) の影響を反映したものと解釈できる。下段の季節成分は、毎年夏に減少し冬に増加する、安定した周期変動を示している。上段の外部イベント効果を見ると、コロナ禍第一波の期間に、他のイベントよりも顕著な正のインパクトが瞬間的に発生していることが視覚的に確認

できる。下段の残差は、全体として特定のパターンを持たないランダムな変動となっており、モデルがデータの主要な構造を十分に捉えられていることを示唆している。

4. 考察

本分析が提示する重要な知見は、コロナ禍が宅配便需要に与えたインパクトが、単一の現象ではなく「持続的なベースラインの上昇」という構造変化と、「第一波における短期的な需要急増」というショックの複合であったと統計的に分離・定量化できた点にある。この複合的な性質の解明は、先行研究のSARIMAモデルでは困難であり、状態空間モデルの優位性を示すものである。また、本モデルは2017年の運賃値上げの影響が、コロナ禍のような巨大な変動を考慮すると統計的に有意でなかったことも示唆した。これは、Eコマース市場の拡大という強力な上昇トレンド (図2) によって、値上げによる仮に存在したであろう負の効果が相殺され、統計的に検出できなくなった可能性が考えられる。あるいは、そもそも宅配便需要の価格弾力性が低く、値上げ幅が需要全体の変動に比べて小さかった可能性も示唆している。

さらに、イベントの性質による影響メカニズムの違いも明らかになった。また、先行研究 (赤羽根, 2024) ではリーマンショック時期のトレンド成長率の鈍化が示唆されたが、本モデルの推定結果では、成長率自体の変化は検出されなかった。これは、先行研究で見られた変動が、成長率の変化ではなく、本モデルが捉えた水準への一時的なショックであった可能性を示している。コロナ禍は需要水準自体の急激な変化として捉えられ、状態空間モデルが多様なショックを表現できることを実証した。これは、物流需要の動態をより深く理解する上で、本モデルが強力な分析ツールであることを示している。

本研究ではコロナ禍を複数のフェーズに分離したが、統計的に有意であったのは

covid_wave1_effectのみであり, covid_mainやcovid_2021は有意ではなかった. これは, これらの影響が本モデルで仮定した「固定期間での瞬間的な水準変化」という単純な形ではなく, トレンドの傾きへの影響や, 徐々に減衰する効果などの複雑な動態を持っていた可能性を示唆している. これらの動的な影響を捉えることは, 今後の課題である.

5. おわりに

本研究は, 状態空間モデルを日本の宅配便取扱個数データに適用し, 先行研究のSARIMAモデルでは困難であった外部イベント効果の分離・定量化を試みた. その結果, 特にコロナ禍のインパクトが社会構造の変化を反映した持続的な需要の底上げと, コロナ禍第一波における短期的な特需という, 複合的な現象である可能性をモデル化し, 特に短期的特需については統計的な有意性($p=0.077$)を確認した. 本研究で得られた知見は, 物流業界が直面する「ラストワンマイル問題」などの経営課題に対し, データに基づいた示唆を与えるものである.

本モデルが示した持続的な構造変化と短期的なショックの分離は, 物流事業者の意思決定に直接的な示唆を与える. 前者は配送センターの新設といった長期的な設備投資の根拠となり得る一方, 後者は短期的な人員配置の最適化や一時的なアウトソーシングの判断材料となる. 本研究では伝統的なアプローチを採用したが, 近年ではRamosら(2024)が提唱する「State Space Learning: SSL」という統計的機械学習を用いたアプローチも登場しており, 今後の応用が考えられる.

参考文献

赤羽根 悠悟 (2024). 日本国内におけるトラック輸送量の時系列予測と分析. 中央大学理工学部卒業論文.
北川 源四郎 (2005). 時系列解析入門. 岩波書店.

国友 直人 (1985). 時系列モデル入門. 東京大学出版会.

Harvey, A. C. (1990). *Forecasting, structural time series models and the Kalman filter*. Cambridge university press.

Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with python. In *9th Python in Science Conference*.

Alqatawna, A., Abu-Salih, B., Obeid, N., & Almiyani, M. (2023). Incorporating time-series forecasting techniques to predict logistics companies' staffing needs and order volume. *Computation*, 11(7), 141.

D. Vališ, D. Mazurkiewicz, and M. Forbelská, "Modelling of a Transport Belt Degradation Using State Space Model," in *IEEE International Conference on Industrial Engineering and Engineering Management (IEEM)*, 2017, pp. 136-140.

Ghareeb, A. (2023). Time series forecasting of stock price for maritime shipping company in COVID-19 period using multi-step long short-term memory (LSTM) networks. In *Proceedings of the 17th International Conference on Business Excellence 2023* (pp. 1728-1747).

Ramos, A., Valladão, D., & Street, A. (2024). *Time Series Analysis by State Space Learning*. arXiv preprint arXiv:2408.09120.

Kaplan, U., Türkay, M., Karasözen, B., & Biegler, L. T. (2011). Optimization of supply chain systems with price elasticity of demand. *INFORMS Journal on Computing*, 23(4), 557-568.

Morganti, E., Seidel, S., Blanquart, C., Dablanc, L., & Lenz, B. (2014). The impact of e-commerce on final deliveries: alterna-

tive parcel delivery services in France and Germany. *Transportation Research Procedia*, 4, 178-190.

Vilko, J., & Hallikas, J. (2024). Impact of COVID-19 on logistics sector companies. *International Journal of Industrial Engineering and Operations Management*, 6(1), 25-42.

Structural Change Analysis of Parcel Delivery Volume in Japan Using State-Space Models

Fuga Terashima* Yugo Akahane** Takumi Fuyuki***
Tomoyuki Higuchi†

* Graduate School of Science and Engineering, Chuo University

** Faculty of Science and Engineering, Chuo University

*** Graduate School of Science and Engineering, Chuo University

† Faculty of Science and Engineering, Chuo University

This study utilizes state-space models (SSMs) to investigate how to separate and quantify the factors influencing the monthly volume of parcel deliveries in Japan, using data from April 2002 to July 2022. While prior research employed SARIMA models, they faced limitations in isolating and quantifying the impact of external events—such as delivery fee hikes and the COVID-19 pandemic—on demand. Therefore, this study constructs multiple SSMs that incorporate a local linear trend and seasonality, while also accounting for these external events.

Based on model comparisons using the Akaike Information Criterion (AIC), a "phased model" was selected for further analysis, as it showed the best fit on this criterion. This model treats the impact of the COVID-19 pandemic using fixed coefficients divided into multiple phases (e.g., structural change, the first wave, and the 2021 wave). This research proposes a framework in which, by leveraging the flexibility of SSMs, the effects of multiple events embedded in complex time series data can be appropriately separated and evaluated according to their respective characteristics. This approach suggests that such modeling can contribute to a more accurate understanding of trends in the logistics industry and inform future forecasting and policy-making.

Key words: state-space model, structural change, time series analysis, COVID-19, logistics