

状態空間モデルを用いた 日本国内のトラック輸送量における時系列分析

寺嶋風雅¹, 赤羽根悠悟², 冬木拓実¹, 樋口知之³

¹ 中央大学大学院 ² 中央大学理工学部 ³ 中央大学理工学部教授

1 はじめに


昨今、EC 市場の急速な拡大に伴い、宅配便は現代社会を支える必須のインフラとなった。一方で、物流業界は「ラストワンマイル問題」に代表される労働力不足や燃料費の高騰といった深刻な課題に直面している。需要の変動を正確に予測できないことは、配送の遅延といったサービス品質の低下や、過剰な人員配置によるコスト増に直結する。したがって、持続可能な物流網を維持するためには、その需要動態を精緻に分析・把握することが不可欠な社会課題となっている。日本国内の宅配便取扱個数の時系列は、単調な増加トレンドだけでなく、消費者の行動や経済情勢を反映した様々な外部ショックの影響を受けてきた。先行研究（赤羽根 2024）では、SARIMA モデルを用いてこの時系列の基本構造が分析されているが、運賃改定やパンデミックといった、性質の異なる複数の外部イベントが与える影響を、互いに分離して定量的に評価するには限界があった。物流需要のモデリングには SARIMA モデルを拡張した SARIMAX モデルも広く用いられている (Alqatawna et al., 2023)。このモデルは外生変数を取り込める点で優れているが、本研究で用いる状態空間モデルは、それに加えてトレンドや季節性といった非観測成分の変動をより柔軟に捉えられる利点がある。本稿の目的は、外的なイベントが与えたインパクトをその性質に応じて分離・定量化することにある。これにより、状態空間モデルが複雑な時系列分析に有効であることを実証するとともに日本の物流動向のより正確な把握に資することが期待される。

2 分析手法

2.1 使用データ

本研究で使用するデータは、国土交通省が公表する「交通関係統計資料」から取得した、2002 年 4 月から 2022 年 7 月までの月次データである。先行研究（赤羽根, 2024）において構築されたデータセットを利用した。主要な変数と宅配便取扱個数の現系列を図 1 に示す。

(a) 主要変数一覧	
カラム名	内容
label	年月 (YYYY-MM-DD)
year	年
month	月
Transport_tonnage	輸送トン数 (トン)
number_parcel	宅配便取扱個数 (千個)
Number_companies_1	輸送トン数の調査会社数 (社)
Number_companies_2	宅配便取扱個数の調査会社数 (社)



(b) 宅配便取扱個数の原系列

図 1: 本研究で利用したデータセットと原系列の概観

2.2 分析モデル

本研究で用いた状態空間モデルは、以下のシステムモデルおよび観測モデルによって表現される。

$$x_t = F_t x_{t-1} + G_t \eta_t \quad (1)$$

$$y_t = H_t x_t + \beta d_t + \epsilon_t \quad (2)$$

ここで、 x_t は状態ベクトル、 y_t は観測値を表す。また、 d_t は次節で定義する外生ダミー変数のベクトルであり、 β は各イベントが与えるインパクトの大きさを示す係数ベクトルである。状態ノイズ項 η_t および観測ノイズ項 ϵ_t は、それぞれ以下の正規分布に従うと仮定する。

$$\begin{bmatrix} \eta_{\mu_t} \\ \eta_{\gamma_t} \end{bmatrix} \sim N\left(0, \begin{bmatrix} \sigma_{\mu_t}^2 & 0 \\ 0 & \sigma_{\gamma_t}^2 \end{bmatrix}\right), \quad \epsilon_t \sim N(0, \sigma_{\epsilon_t}^2) \quad (3)$$

また、状態ベクトル x_t はトレンド成分と周期 12 の季節成分から構成され、 F_t, G_t, H_t はそれぞれ以下のように定義される。

$$x_t = \begin{bmatrix} \mu_t \\ \delta_t \\ \gamma_t \\ \vdots \\ \gamma_{t-11} \end{bmatrix}, \quad F_t = \begin{bmatrix} 1 & 1 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & -1 & \dots & -1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{bmatrix}, \quad H_t = \begin{bmatrix} 1 & 0 & 1 & 0 & \dots & 0 \end{bmatrix}^T \quad (4)$$

2.3 外生変数の設計

本研究で用いる状態空間モデルでは、観測方程式に外生変数を加えることで、外部イベントの影響を分離・定量化できる。分析期間中の主要イベントである 2017 年の運賃値上げと新型コロナのパンデミックを捉えるため、それぞれの期間を 1、それ以外を 0 とするダミー変数を設計した。モデルはこれらの変数に対する係数 β を推定し、各イベントのインパクトを評価する。具体的な変数設計は表 1 に示す通りである。

表 1: 外生変数として導入するダミー変数一覧

変数名	対象期間	説明
hike_dummy	2017/10 – 2019/12	2017 年 10 月に実施された主要各社の運賃値上げの影響を捉える変数。
covid_main	2020/03 –	COVID-19 パンデミックによる巣ごもり需要の定着など、市場構造そのものに与えた持続的な変化と捉える変数。
covid_wave1	2020/04 – 2020/05	緊急事態宣言下での急激な需要増など、パンデミック初期の短期的なインパクトを捉える変数。
covid_2021	2021/01 – 2021/09	感染再拡大に伴う断続的な需要増の影響を捉える変数。

2.4 比較モデル

本研究で採用する提案モデルの優位性、および各外部イベントが与える影響の重要性を評価するため、以下の 3 つの状態空間モデルを構築し、比較検討を行った。各モデルは、2.2 節で述べた基本構造を共有しつつ、2.3 節で設計した外生変数の組み込み方が異なる。

- **ベースラインモデル**: 確率的トレンド成分と季節成分のみで構成されるモデル。外部イベントの影響を一切考慮しない、最も基本的なモデルであり、分析の基準点となる。
- **単純イベントモデル**: ベースラインモデルに加え、運賃値上げダミーと、コロナ禍の影響を単一のダミー変数 (covid_main) のみで表現したモデル。イベントの影響を単純化した形で評価する。
- **提案モデル**: ベースラインモデルに加え、運賃値上げダミーと、コロナ禍の影響をその性質に応じて複数のフェーズに分けたダミー変数群 (covid_main, covid_wave1, covid_2021) を全て組み込んだ、本研究における提案モデルである。

これらの 3 モデルをそれぞれ推定し、モデルの当てはまりの良さを情報量規準 AIC によって評価した。その比較結果は次章で詳述する。

3 分析結果

3.1 モデルの比較と選択

2.4 節で定義した 3 つのモデルを推定し、対数尤度、AIC、BIC を算出した。結果を表 2 に示す。

表 2: モデルの比較

モデル	対数尤度	AIC	BIC
1. ベースラインモデル	471.9	-913.9	-861.4
2. 単純イベントモデル	477.5	-915.0	-855.1
3. 提案モデル	480.9	-919.9	-846.4

比較の結果,「3. 提案モデル」が,最も低い AIC 値 (-919.9) を示した. したがって, 本稿ではこの提案モデルを最終的な分析に用いることとする.

3.2 提案モデルの推定結果

提案モデルのパラメータ推定結果を表 3 に示す. なお, 各モデルのパラメータ推定にあたっては初期値依存を避け安定した解を得るため, 複数の初期値候補によるグリッドサーチによって最尤解を探索した.

表 3: 提案モデルのパラメータ推定結果

パラメータ	推定値 (coef)	標準誤差 (std err)	p 値 ($P_{ t -z}$)
外生変数効果			
hike_effect	-0.023	0.031	0.464
covid_main_effect	0.049	0.040	0.222
covid_wave1_effect	0.045	0.026	0.077
covid_2021_effect	0.020	0.015	0.184
分散パラメータ			
観測ノイズ (σ_ϵ^2)	0.0003	4.35e-05	0.000
トレンドノイズ (σ_μ^2)	8.66e-05	2.29e-05	0.000
傾きノイズ (σ_δ^2)	2.46e-11	2.61e-08	0.999
季節ノイズ (σ_γ^2)	5.30e-05	1.63e-05	0.001

表 3 から, コロナ禍第一波の効果 (covid_wave1_effect) の係数が約 0.045 であり, 10%水準で統計的に有意であったことが確認できる ($p=0.077$). これは, 最初の緊急事態宣言下において, 他の要因に加えて約 4.5%の追加的な需要増があったことを示唆している.

3.3 時系列の成分分解

提案モデルによる分解結果を 2 に示す.




図 2: 提案モデルによる時系列成分の分解

図 2(a) 上段の観測値とフィット値の比較から, モデルが実際のデータの変動を非常によく捉えていることがわかる. 中段のトレンド成分は, 分析期間を通して一貫した上昇傾向にあるが, 2008 年や 2014 年付近で一時的な成長

の鈍化が見られる。下段の季節成分は、毎年夏に減少し冬に増加する、安定した周期変動を示している。図 2(b) 上段の外部イベント効果を見ると、コロナ禍第一波の期間に、他のイベントよりも顕著な正のインパクトが瞬間的に発生していることが視覚的に確認できる。下段の残差は、全体として特定のパターンを持たないランダムな変動となっており、モデルがデータの主要な構造を十分に捉えられていることを示唆している。

4 考察

本分析が提示する重要な知見は、コロナ禍が宅配便需要に与えたインパクトが、単一の現象ではなく「持続的なベースラインの上昇」という構造変化と、「第一波における短期的な需要急増」というショックの複合であったと統計的に分離・定量化できた点にある。この複合的な性質の解明は、先行研究の SARIMA モデルでは困難であり、状態空間モデルの優位性を示すものである。また、本モデルは 2017 年の運賃値上げの影響が、コロナ禍のような巨大な変動を考慮すると統計的に有意でなかったことも示唆した。さらに、イベントの性質による影響メカニズムの違いも明らかになった。リーマンショックがトレンド成長率の鈍化として現れた一方、コロナ禍は需要水準自体の急激な変化として捉えられ、状態空間モデルが多様なショックを表現できることを実証した。これは、物流需要の動態をより深く理解する上で、本モデルが強力な分析ツールであることを示している。

5 おわりに

本研究は、状態空間モデルを日本の宅配便取扱個数データに適用し、先行研究の SARIMA モデルでは困難であった外部イベント効果の分離・定量化を試みた。その結果、特にコロナ禍のインパクトが社会構造の変化を反映した持続的な需要の底上げと、第一波における短期的な特需という、性質の異なる複合的な現象であったことを統計的に解明した。本研究で得られた知見は、物流業界が直面する「ラストワンマイル問題」などの経営課題に対し、データに基づいた示唆を与えるものである。例えば、一時的な需要増と恒久的な構造変化を識別する本モデルの分析は、事業者が行うべき投資（長期的な設備増強か、短期的な人員配置の最適化か）の判断を支援する。本研究では伝統的なアプローチを採用したが、近年では Ramos ら (2024) が提唱する「State Space Learning: SSL」という統計的機械学習を用いたアプローチも登場しており、今後の応用が考えられる。

謝辞

本研究を進めるにあたり、基盤となる時系列データに関して、中央大学理工学部 機械学習研究室の赤羽根悠悟氏 (2024 年度卒業) が構築されたデータを使用させていただきました。ここに記して、深く感謝の意を表します。

参考文献

- [1] 赤羽根 悠悟 (2024). 日本国内におけるトラック輸送量の時系列予測と分析. 中央大学理工学部卒業論文.
- [2] Harvey, A. C. (1990). *Forecasting, structural time series models and the Kalman filter*. Cambridge university press.
- [3] Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with python. In *9th Python in Science Conference*.
- [4] Alqatawna, A., Abu-Salih, B., Obeid, N., & Almiani, M. (2023). Incorporating time-series forecasting techniques to predict logistics companies' staffing needs and order volume. *Computation*, 11(7), 141.
- [5] D. Vališ, D. Mazurkiewicz, and M. Forbelská, "Modelling of a Transport Belt Degradation Using State Space Model," in *IEEE International Conference on Industrial Engineering and Engineering Management (IEEM)*, 2017, pp. 136-140.
- [6] Ghareeb, A. (2023). Time series forecasting of stock price for maritime shipping company in COVID-19 period using multi-step long short-term memory (LSTM) networks. In *Proceedings of the 17th International Conference on Business Excellence 2023* (pp. 1728-1747).
- [7] Ramos, A., Valladão, D., & Street, A. (2024). *Time Series Analysis by State Space Learning*. arXiv preprint arXiv:2408.09120.