

宅配便取扱個数の構造変化に関する時系列分析 —状態空間モデルによる分解と予測評価—

寺嶋 風雅¹・赤羽根 悠吾²・冬木 拓実¹・樋口 知之³

¹ 会員区分：非会員 所属 1：中央大学大学院

² 会員区分：非会員 所属 2：中央大学

³ 会員区分：非会員 所属 3：中央大学理工学術院

E-mail：要確認 Corresponding Author：要確認

要旨：本研究は、日本の宅配便取扱個数の月次系列を対象に、状態空間モデルを用いて構造変化をトレンド、季節成分およびイベント効果に分解する分析枠組みを提示する。後続統計への接続を行った系列について、COVID-19期、統計接続後および運賃改定期をイベントとして扱う。さらに、トレンド仕様等のモデル仕様に対する推定結果の頑健性を確認し、限定的な予測評価を行う。結果の解釈は今後の分析に基づき整理する。

キーワード：宅配便取扱個数、状態空間モデル、構造変化、時系列分析、予測評価

1. はじめに

宅配便取扱個数は、物流需要や消費行動の変化を月次で把握するための重要な系列である。宅配便は日常生活と企業活動を支える物流基盤であり、その取扱動向は物流サービスの利用状況や輸送需要の変化を検討する基礎資料となる。近年は、電子商取引の利用拡大、運賃改定、COVID-19期の行動変化など、取扱個数に関係し得る要因が複合化している。ただし、観測された変動が特定の要因によって生じたと因果的に断定するには、個別要因に関する追加情報と識別設計が必要である。そこで、観測系列を長期トレンド、月次季節性、特定期間に対応する水準差に分けて把握し、各成分の解釈範囲を明確にする必要がある。本研究では、これらの要因を因果効果としてではなく、指定期間に対応するモデル上の水準差として扱う。

宅配便取扱個数の月次系列には、長期的なトレンド、月次季節性、特定期間に対応する水準差が重なっている。さらに、2022年8月以降は旧統計から後続統計への切替があり、両統計は対象事業者や集計範囲が完全に同一ではない。このため、接続後の系列に現れる水準差をそのまま需要の変化として読むことには注意を要する。観測系列を適切に解釈するには、長期トレンド、季節成分、運賃改定期やCOVID期に対応するイベント期間の水準差、および統計接続後の水準補正を分けて記述する必要

がある。

関連研究では、宅配便取扱個数の長期的な月次系列を構築し、状態空間モデルを用いてトレンド、季節性および外部イベントに対応する変動を分離する枠組みが検討されてきた。旧稿においても、宅配便取扱個数を対象として、ローカル線形トレンドと季節成分を含む時系列モデルにより外部要因を記述する問題設定が示されている。しかし、旧稿の統計期間やイベント定義は現在の分析対象と一致しない。そこで本稿では、旧統計と後続統計を接続した現行の長期系列を用い、統計接続後の水準補正を明示的に導入する。また、トレンド仕様の変更に対する頑健性確認と、情報条件を明示した補助的な予測評価を加えることで、構造分解結果の解釈範囲を整理する。

本研究の目的は、日本の宅配便取扱個数の長期月次系列を対象に、状態空間モデルを用いて観測系列の構造変化を分解することである。具体的には、接続済み系列に対して、トレンド、月次季節成分、運賃改定期およびCOVID期などのイベント期間に対応する水準差、ならびに後続統計への切替に伴う水準補正を同一の枠組みで扱う。さらに、傾き擾乱を0に固定した固定傾きモデルなどとの比較により、中心的な結果がトレンド仕様にどの程度依存するかを確認する。直近期間の予測評価は、評価期間の外生ダミーを既知とする条件付き予測として実施し、構造分解モデルの補助的な検証に位置づける。

本研究の貢献は、第一に、旧統計と後続統計を接続した宅配便取扱個数系列を用い、統計接続後の水準差を需要変化と区別して扱う点にある。第二に、状態空間モ

デルにより、長期トレンド、季節成分およびイベント期間に対応する水準差を分解して記述する点にある。第三に、トレンド仕様の頑健性確認と条件付き予測評価により、主結果の解釈範囲を補助的に確認する点にある。これらは、特定イベントの因果効果や単一の予測手法の恒常的な優位を主張するものではなく、統計接続を含む観測系列を構造的に記述するための分析上の整理である。

本稿の構成は以下のとおりである。第2章では、使用する旧統計および後続統計、接続方法、目的変数とイベント設定を説明する。第3章では、状態空間モデルの観測方程式、トレンド・季節成分、イベント効果および比較仕様を定義する。第4章では、主仕様による構造変化の推定結果を示す。第5章では、固定傾きモデル、水準ノイズ制約モデルおよび決定的線形トレンドモデルを用いて、モデル仕様の頑健性を確認する。第6章では、無条件予測と条件付き予測の情報条件を区別した予測評価を行う。第7章では、得られた知見、限界および今後の課題をまとめる。

2. 使用データとイベント設定

(1) 使用データ

本研究では、国土交通省「トラック輸送情報」に掲載された宅配便貨物取扱個数と、同統計の廃止後に国土交通省「国土交通月例経済」（交通分野）で公表される宅配便貨物取扱個数を用いる。前者は2002年4月から2022年7月までの244か月、後者は2022年8月から2026

(3) イベント変数

主仕様では、表-1に示す5つの期間ダミーを用いる。運賃改定期ダミーは2017年10月から2019年12月まで、COVID期ダミーは2020年3月から2023年5月まで、COVID初期波ダミーは2020年4月から5月まで、2021年局面ダミーは2021年1月から9月まで、後続統計ダミーは2022年8月以降を1とする。COVID初期波ダミーおよび2021年局面ダミーはCOVID期ダミーと重複し、COVID期に対応する持続的な水準差に対して、それぞれの局面における追加的な水準差を表現する。COVID期ダミーの終点である2023年5月は、COVID-19の5類感染症移行時期までを含める期間として設定したものであり、その選択の頑健性は第5章で確認する。

各ダミーは、指定期間に対応するモデル上の水準差を表す変数である。観測されない需要要因、事業者別の料

年2月までの43か月であり、分析対象は計287か月の月次系列である。宅配便取扱個数は千個単位で記録されている。旧統計の宅配貨物取扱事業者は2022年7月時点で大手14社であるのに対し、後続統計はヤマト運輸、SGホールディングスおよび日本郵便の大手3社に基づく。したがって、両系列は同じ母集団を観測した完全に同質な系列ではない。

(2) 統計接続と目的変数

接続済み系列では、2022年7月までの旧統計と2022年8月以降の後続統計の宅配便取扱個数を月次で直接連結する。保存されている資料からは、比率補正又は水準合わせを行った処理は確認されない。そこで、後続統計への切替後に生じ得る対象範囲・集計方法の差を需要変化と区別するため、2022年8月以降を1とする後続統計ダミーを状態空間モデルに含める。これは統計接続に伴う水準補正項であり、需要減少又は統計変更の因果効果を表すものではない。

目的変数は、接続済み宅配便取扱個数の自然対数として、次式で定義する。

$$y_t = \log(q_t). \quad (1)$$

ここで、 q_t は時点 t の宅配便取扱個数である。この変換により、イベント係数は対数取扱個数に対する比率的な水準差として読みやすくなる。ただし、本研究の目的は観測された時系列の構造分解であり、係数を宅配需要に対する事象の因果効果として解釈するものではない。

金・サービス変更、その他の社会経済要因を網羅的に統制するものではないため、運賃改定期又はCOVID期の因果効果を示すものではない。また、旧統計を全期間にわたり同一定義の系列とみなさないことに留意する。

3. 分析方法

(1) 状態空間モデルの構成

第2章で定義した対数宅配便取扱個数を、トレンド、月次季節成分、イベントに対応する水準差および観測誤差に分解する。時点 t の観測方程式を次式で表す。

$$y_t = \mu_t + \gamma_t + \beta' d_t + \varepsilon_t. \quad (2)$$

ここで、 y_t は対数宅配便取扱個数、 μ_t はトレンド成分、 γ_t は季節成分、 d_t はイベントダミーのベクトル、 β はその係数ベクトル、 ε_t は観測誤差である。本研究では、これらの成分を状態空間表現により同時に推定すること

表1 使用データおよびイベント変数の定義

(a) 使用データ・目的変数		
区分	内容	本研究での扱い
旧統計	国土交通省「トラック輸送情報」の宅配便貨物取扱個数. 2002年4月–2022年7月, 244 か月, 千個.	2022年7月時点では大手14社. 長期系列内の対象事業者数の変化に留意する.
後続統計	国土交通省「国土交通月例経済」(交通分野)の宅配便貨物取扱個数. 2022年8月–2026年2月, 43 か月, 千個.	ヤマト運輸, SGホールディングス, 日通. 本郵便の大手3社に基づく.
接統済み系列	旧統計と後続統計を2022年8月で直接連結した宅配便取扱個数系列. 2002年4月–2026年2月, 287 か月.	比率補正・水準合わせは確認されていない. 後続統計期間を1とするダミーを用いる.
目的変数	$y_t = \log(q_t)$	状態空間モデルでは対数取扱個数を用いる.

(b) イベント変数 (該当月を1, それ以外を0)		
イベント	期間	モデル上の役割・解釈
運賃改定期	2017年10月–2019年12月	操作的に設定した運賃改定期の水準差を制御する期間ダミーである.
COVID 期	2020年3月–2023年5月	COVID 期に対応する主たる水準差である.
COVID 初期波	2020年4月–2020年5月	初期波に対応する追加的な短期水準差であり, COVID 期と重複する.
2021 年局面	2021年1月–2021年9月	操作的に設定した2021年局面の追加的な水準差であり, COVID 期と重複する.
後続統計接続	2022年8月以降	後続統計への接続に伴う水準補正であり, 需要減少を表す変数ではない.

注1: 旧統計には2018年4月の一部事業者における集計方法変更により, それ以前との時系列上の連続性が担保されない旨の注記がある.

注2: イベントダミーは指定期間に対応するモデル上の水準差を表すものであり, 各事象の因果効果を示すものではない.

で, 長期的な変動と特定期間に対応する水準差とを区別する.

(2) トレンドおよび季節成分

主仕様(局所線形トレンドモデル, 以下, 主仕様)のトレンドには, 水準と傾きの双方の時間的変化を許す local linear trend を用いる. 状態方程式は次式である.

$$\mu_{t+1} = \mu_t + \delta_t + \eta_{\mu,t}, \quad (3)$$

$$\delta_{t+1} = \delta_t + \eta_{\delta,t}. \quad (4)$$

ここで, δ_t はトレンドの傾き, $\eta_{\mu,t}$ および $\eta_{\delta,t}$ は, それぞれ水準および傾きの状態擾乱である. この構造により, トレンドは月次系列の長期的な変動に応じて水準と傾きを変化させることができる. 季節成分 γ_t は, 12 か月周期の繰返しを表す月次の状態成分として導入する. 季節性をトレンドやイベント効果から分離することにより, 特定月に集中する変動をイベントに帰属させすぎないようにする.

(3) イベント効果と係数の解釈

イベントダミーのベクトルは,

$$\mathbf{d}_t = \begin{pmatrix} hike_t \\ covid_t \\ wave1_t \\ covid21_t \\ poststat_t \end{pmatrix} \quad (5)$$

とする. 各変数が1となる期間は表-1に示したとおりである. COVID 初期波ダミーおよび2021年局面ダミーはCOVID 期ダミーと重複し, COVID 期に対応する持続的な水準差に加えて, それぞれの局面における追加的な水準差を表現する. 後続統計ダミーは後続統計への接続に伴う水準補正を表す変数であり, 宅配需要の減少を意味する変数としては扱わない.

目的変数が対数尺度であるため, イベント変数 j の係数 β_j は, 必要に応じて $\exp(\beta_j) - 1$ により比率的な水準差へ換算できる. ただし, これらの係数は指定期間に対応するモデル上の水準差である. 観測されない需要要因, 事業者別の料金・サービス変更および他の社会経済要因を網羅的に統制するものではないため, 各事象の因果効果として解釈しない.

(4) 比較仕様

第5章では、トレンド仮定に対する主結果の頑健性を確認する。固定傾きモデル（傾き擾乱を0に固定した仕様、以下、固定傾きモデル）は、式(3)の水準擾乱を残したまま、式(4)の傾き擾乱を0に固定するものである。したがって、主仕様と固定傾きモデルの差は、傾きの時間変化を許すか否かにある。両仕様では、季節成分および式(5)のイベントダミーを共通に用いる。

(5) 推定、診断および予測評価

パラメータは状態空間モデルの尤度に基づき推定する。仕様間の比較には、対数尤度、AIC および BIC を用いる。また、残差に自己相関が残らないかを確認するため、Ljung-Box 検定等の残差診断を行う。これらの診断結果は、係数および分解結果の解釈範囲を検討するための情報として第4章および第5章で示す。

予測面からの補助的な検証として、第6章では直近期間評価を行う。直近期間評価では、2002年4月から2023年12月を学習期間、2024年1月から2026年2月を評価期間とする。予測精度は原系列の取扱個数尺度で RMSE, MAE, MAPE および MASE により評価する。状態空間モデルの conditional forecast では、評価期間における式(5)の外生ダミーを既知として与える。この評価は、既知のイベント情報を条件とした予測であり、将来のイベント発生を無条件に予測する実運用上の精度を直接表すものではない。したがって、外生情報を用いない予測との比較では、情報条件の違いを区別して解釈する。

4. 状態空間モデルによる構造変化の推定結果

本章では、第2章で定義した接続済み宅配便取扱個数系列に対する主仕様の推定結果を示す。




図1 主仕様の成分分解

(1) 主仕様の適合と成分分解

主仕様は287か月の対数系列に対して収束し、対数尤度は584.0694である。観測値と適合値、トレンド、季節成分および残差を図1に示す。

観測値と適合値は、月次の季節変動と長期的な水準上昇に概ね追従している。ただし、適合値と観測値の差が全期間で小さいことを意味するものではなく、残差診断を踏まえて解釈する必要がある。トレンド成分は長期的な上昇を基本としつつ時期により水準の変化を示し、季節成分は月次の周期変動を表している。これらを状態成分として明示的に分離することで、季節的な変動をイベント項や長期トレンドに過度に帰属させることを避けている。

残差は平均の周囲で変動し、一部の時点で比較的大きな正負の乖離を示す。残差標準偏差は0.01072、RMSEは0.01070である。これらは対数尺度の値であり、原系列の個数単位の誤差ではない。

(2) イベント係数の推定結果

イベント係数を表2に示す。推定値は対数尺度であり、比率換算値は $100\{\exp(\hat{\beta}_j) - 1\}$ により計算した。各係数は指定期間に対応するモデル上の水準差であり、イベントの因果効果を表すものではない。

運賃改定期ダミーは負方向の水準差（-2.308%）であるが、これは指定した期間に対応する条件付きの値であり、運賃改定による需要の因果的变化や価格弾力性を推定したものではない。COVID 期ダミーは +3.094%、COVID 初期波ダミーは +5.253%、2021 年局面ダミーは +1.631% であり、初期波の指定期間に対応する水準差が相対的に大きい。これらも固定期間を設定したモデル上の関係として解釈する。

表 2 主仕様のイベント係数推定結果

変数	推定値	標準誤差	p 値	比率換算値
運賃改定期	-0.02335	0.02721	0.3909	-2.308%
COVID 期	0.03047	0.01865	0.1023	+3.094%
COVID 初期波	0.05120	0.01787	0.0042	+5.253%
2021 年局面	0.01618	0.01263	0.2001	+1.631%
後続統計接続	-0.04530	0.02464	0.0660	-4.429%

注) 比率換算値は $100\{\exp(\hat{\beta}_j) - 1\}$ 。係数は指定期間に対応するモデル上の水準差であり、因果効果ではない。p 値は残差自己相関を踏まえ参考情報として扱う。

(3) 統計接続後の水準補正

後続統計ダミーの推定値は-0.04530、比率換算で-4.429%である。この変数は2022年8月以降を1とする統計接続用のダミーであり、旧統計から後続統計へ切り替わった後の系列水準をモデル内で補正するために導入した。したがって、負の係数を後続統計期間における宅配便需要の減少や市場縮小とは解釈しない。また、この係数は他のイベントダミー、トレンドおよび季節成分を同時に含む条件付きの水準差である。

(4) 残差診断と頑健性確認への橋渡し

主仕様の残差に対する Ljung-Box 検定の p 値は、ラグ 12 で 2.19×10^{-7} 、ラグ 24 で 1.08×10^{-5} であった。いずれも小さく、残差自己相関が残っている可能性が示される。したがって、残差を白色雑音とみなしたり、適合値のみからモデルの十分性を断定したりせず、表 2 の p 値もこの診断上の留保を踏まえて参考情報として扱う。

一方、主仕様で推定された傾きノイズは 2.26×10^{-11} と極めて小さい。これは傾き状態の確率的変動が小さい可能性を示すが、傾きノイズが厳密にゼロであることを意味しない。第 5 章では、傾きノイズを 0 に固定した固定傾きモデルを頑健性確認仕様として扱い、イベント係数、分解および診断がトレンド仕様にどの程度依存するかを確認する。

5. モデル仕様の頑健性確認

本章では、主仕様として、傾きノイズを 0 に固定した固定傾きモデル、水準ノイズを段階的に制約した水準ノイズ制約モデル (TR1b-TR1d)、および決定的線形トレンドモデル (TR2) を比較する。数値は感度分析結果を丸めて示す。イベント係数は、指定期間に対応するモデル上の水準差であり、因果効果として解釈しない。

(1) 固定傾き仕様との比較

主仕様と固定傾きモデルは、287 か月の同一系列、同一の季節成分および 5 個のイベントダミーを用い、傾きノイズの扱いだけが異なる。主仕様の傾きノイズ推定値は 2.3×10^{-11} で境界に近く、固定傾きモデルではこれを 0 に固定した。両仕様は収束し、対数尤度はともに約 584.1 である。AIC は主仕様の -1124.1 に対して固定傾きモデルが -1126.1、BIC は -1043.6 に対して -1049.3 であり、固定傾きモデルがわずかに小さい。ただし、この差はほぼ同じ尤度で推定パラメータを 1 つ減らしたことによる情報量基準の差であり、固定傾きモデルの全面的な優位を示すものではない。

主要イベント係数の比率換算値は、主仕様から固定傾きモデルへ変更しても大きく変化しない。運賃改定期ダミーはともに -2.3%、COVID 期ダミーは +3.1% 前後、COVID 初期波ダミーは +5.3% 前後、2021 年局面ダミーは +1.6%、後続統計ダミーは -4.4% 前後である。したがって、COVID 初期波に対応する正方向の水準差と統計接続後の水準補正を区別するという主結果は、傾きノイズの有無に大きく依存しないと整理できる。ただし、後続統計ダミーは需要減少ではなく、統計接続に伴う水準補正として読む必要がある。

残差標準偏差は両仕様とも約 0.0107 であり、Ljung-Box 検定の p 値もラグ 12 で約 2.2×10^{-7} 、ラグ 24 で約 1.1×10^{-5} と近い。固定傾き化によって残差自己相関が解消したとはいえない。以上から、固定傾きモデルは主仕様と同等の簡約仕様として、主結果の頑健性を確認する最重要仕様に位置付ける。

(2) 水準ノイズ制約によるトレンド硬さの比較

水準ノイズ制約モデル (TR1b-TR1d) では、固定傾きモデルで推定された水準ノイズ分散を基準とし、その 0.5、0.25、0.1 倍に固定した。制約を強めると、対数尤度は約 581.0、572.3、555.0 へ低下し、AIC も -1122.0、-1104.7、-1070.1 へ上昇した。残差標準偏差も約 0.0128

から 0.0179 へ増加し、トレンドを硬くするほど適合度が悪化する傾向が確認される。

係数の方向は概ね維持されるものの、水準ノイズの制約に応じて大きさが変化する。例えば、COVID 期ダミーの比率換算値は水準ノイズ制約モデル（TR1b–TR1d）でそれぞれ +3.6%, +4.0%, +4.4%, 後続統計ダミーは -5.2%, -5.7%, -5.8% である。この結果は、主仕様と固定傾きモデルの間で得られた安定性を、任意の硬いトレンド仕様に対する安定性へ一般化できないことを示す。水準ノイズ制約は、イベント期間に対応する水準差をトレンドから切り分ける方法そのものに影響するため、本稿では感度分析として報告する。

(3) 決定的線形トレンドモデルの扱い

決定的線形トレンドモデル（TR2）は、推定が未収束であった。対数尤度は約 531.0, AIC は -1022.0, BIC は -948.8 で、主仕様、固定傾きモデルおよび水準ノイズ制約モデルより適合度が低い。残差標準偏差も約 0.0271 と大きく、Ljung–Box 検定の p 値はラグ 12, 24 とともに極めて小さい。したがって、決定的線形トレンドモデルの係数や適合度を主結論の根拠には用いず、硬すぎるトレンド仮定が構造分解を不安定にし得ることを示す参考結果として扱う。

(4) 本章のまとめ

主仕様と固定傾きモデルは、情報量基準、主要イベント係数、残差標準偏差および残差診断がほぼ同じであり、主結果は傾きノイズを推定するか 0 に固定するかに大きく依存しない。一方、水準ノイズを強く制約すると適合度が低下し、COVID 期ダミーおよび後続統計ダミーの水準差も変化する。決定的線形トレンドモデルは未収束であり、参考仕様にとどめる。以上より、本稿では主仕様を中心とし、固定傾きモデルを最重要の頑健性仕様とする方針を支持する。ただし、残差自己相関が残るため、いずれの仕様についても係数の p 値や適合度を過度に強調せず、固定期間ダミーに基づくモデル上の水準差として解釈する。

6. 予測評価

本章では、状態空間モデルによる構造分解を補助的に検証するため、接続済み宅配便取扱個数系列の予測評価を行う。複数の手法について恒常的な精度優位を主張するのではなく、主仕様と固定傾きモデルの予測挙動が大きく異ならないかを確認することを目的とする。評価の

中心には、直近期間を対象とする評価設定を置く。

直近期間評価では、2002 年 4 月から 2023 年 12 月までの 261 か月を学習期間、2024 年 1 月から 2026 年 2 月までの 26 か月を評価期間とした。評価指標は、実測値と予測値を原系列の宅配便取扱個数スケールに戻して計算した RMSE, MAE, MAPE および MASE である。比較対象には、前年同月値を用いる季節ナীব、主仕様に対応する SSM（主仕様）、固定傾きモデルに対応する SSM（固定傾き）を採用した。

予測の情報条件を区別する必要がある。季節ナীবは将来の外生変数を用いない unconditional forecast である。一方、SSM の conditional forecast は、評価期間における運賃改定期ダミー、COVID 期ダミー、COVID 初期波ダミー、2021 年局面ダミーおよび後続統計ダミーの値を既知として与えた予測である。したがって、両者の指標を同一の情報条件に基づく単純な順位として解釈せず、各条件下の予測誤差として読む必要がある。

表-3 に直近期間評価の結果を示す。季節ナীবの RMSE, MAE, MAPE および MASE は、それぞれ 13,623, 11,620, 2.91%, 0.929 であった。これに対し、SSM（主仕様）は 8,113, 6,756, 1.72%, 0.540, SSM（固定傾き）は 8,135, 6,729, 1.71%, 0.538 である。両 SSM は近い値を示し、傾きノイズを固定したことによる予測差は限定的である。ただし、RMSE では主仕様が、MAE, MAPE および MASE では固定傾きモデルがわずかに小さく、いずれか一方の仕様が一貫して優れるとはいえない。

参考として、季節性を含む回帰型時系列モデルの探索結果は、RMSE 7,975, MAE 6,701, MAPE 1.71%, MASE 0.536 であり、SSM と近い水準であった。ただし、モデル間で情報条件、推定手順および仕様が同一ではないため、この結果を予測精度の順位付けの根拠とはしない。

表 3 直近期間評価における予測評価

モデル	RMSE	MAE	MAPE(%)	MASE
季節ナীব	13,623	11,620	2.91	0.929
SSM（主仕様）	8,113	6,756	1.72	0.540
SSM（固定傾き）	8,135	6,729	1.71	0.538

注）季節ナীবは unconditional, SSM は評価期間の外生ダミーを既知として与えた conditional forecast である。指標は原系列スケールで計算した。

COVID one-year 設定では、2002 年 4 月から 2021 年 2 月までの 227 か月を学習期間、2021 年 3 月から 2023 年 5 月までの 27 か月を評価期間とした。SSM（主仕様）の RMSE, MAE, MAPE および MASE は 18,236, 14,561, 3.67%, 1.180, SSM（固定傾き）は 18,245, 14,565, 3.67%, 1.180 であり、両仕様はほぼ同じであった。一方、この学習期間では後続統計ダミーが一定値となるため、該当する統計接続後の水準補正を学習できず、この

結果は直近期間評価と同列の主評価ではなく補助的な確認として扱う。

以上の予測評価は、既知のイベントダミーを条件とする SSM 予測と、外生変数を用いない季節ナイーブ予測を並べたものである。SSM が将来のイベントを無条件に予測できたことや、いずれの条件でも予測精度が常に優れることを示すものではない。直近期間評価において主仕様と固定傾きモデルの指標が概ね同程度であったことから、傾きノイズの扱いが予測評価を大きく左右しないことが補助的に確認された。

7. 結論

本研究は、日本の宅配便取扱個数の長期月次系列を対象に、状態空間モデルを用いて観測系列の構造変化を分解したものである。旧統計と後続統計を接続した系列について、長期的なトレンド、月次季節成分、指定したイベント期間に対応する水準差、および後続統計への切替に伴う水準補正を同一の枠組みで扱った。これにより、統計系列の継続性に起因する変化と、特定期間に対応する変動とを区別して記述するための基礎を示した。

主仕様による分解では、宅配便取扱個数の長期的な上昇傾向と月次季節性を状態成分として表現し、運賃改定期および COVID 期の各イベント期間に対応する水準差をこれらと分けて推定した。COVID 初期波に対応する期間では、COVID 期全体に対応する水準差に加えて、相対的に大きい正方向の水準差が得られた。一方、後続統計ダミーは負方向の水準差を示したが、これは対象範囲や集計方法の違いを含む統計接続に伴う水準補正であり、後続統計期間の需要減少や市場縮小を表すものではない。これらの係数は、いずれも指定期間に対応するモデル上の水準差として解釈すべきである。

モデル仕様の頑健性については、傾き擾乱を 0 に固定した固定傾きモデルにおいて、主要イベント係数、残差標準偏差および残差診断が主仕様と大きく異ならなかった。この範囲では、傾きノイズを推定するか否かによって中心的な分解結果が大きく変わらないことが示された。ただし、水準ノイズを強く制約したモデルでは適合度が低下し、COVID 期および後続統計接続に対応する水準差も変化した。したがって、トレンド仕様に対する

頑健性は主仕様と固定傾きモデルの範囲で述べるべきであり、トレンドを過度に硬くした場合まで一般化することはできない。

予測評価は、構造分解モデルの補助的な検証として実施した。直近期間の評価では、主仕様と固定傾きモデルの予測指標は概ね同程度であったが、状態空間モデルの予測は、評価期間における外生ダミーを既知として与えた条件付き予測である。このため、その結果は外生情報を用いない無条件の将来予測能力や、特定の手法が常に優れることを示すものではない。予測評価は、トレンド仕様の変更が予測挙動を大きく損なわないことを確認する補足的な結果として位置づける。

本研究にはいくつかの限界がある。旧統計と後続統計は対象事業者や集計範囲が完全に同一ではなく、接続後の水準補正を導入しても両系列の非同質性を完全に解消するものではない。また、イベントダミーは分析上設定した操作的な期間変数であり、各事象の因果効果を識別するものではない。さらに、残差自己相関が残っているため、係数の p 値や適合度は参考情報として慎重に扱う必要がある。今後は、事業者別情報や連続的な外生変数を取り入れた分析、イベント効果の時変性を許すモデル、および将来の外生情報を未知とするより厳密な予測設定を検討することが課題である。

REFERENCES

参考文献

- [1] James Durbin and Siem Jan Koopman. *Time Series Analysis by State Space Methods*. Oxford University Press, Oxford, 2nd edition, 2012.
- [2] Andrew C. Harvey. *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press, Cambridge, 1989.
- [3] Ministry of Land, Infrastructure, Transport and Tourism. Monthly economic cargo statistics. Official statistics data, 2026. Accessed August 3, 2026. Placeholder bibliographic record; replace with the final Japanese source citation.

(Received ?)

(Accepted ?)

TIME SERIES ANALYSIS OF STRUCTURAL CHANGES IN PARCEL DELIVERY VOLUMES: DECOMPOSITION AND FORECAST EVALUATION USING A STATE SPACE MODEL

Fuga TERASHIMA¹, Yugo AKABANE², Takumi FUYUKI², and Tomoyuki
HIGUCHI²

This provisional study examines monthly Japanese parcel delivery volumes after linking successor statistics. A state space model is used to decompose structural changes into trend, seasonal components, and event effects. The analysis considers the COVID-19 period, the period after the statistical linkage, and freight-rate revision periods. It will examine the robustness of the estimates to alternative model specifications and conduct limited forecast evaluations. The empirical findings and their interpretation remain to be finalized.

Key Words: *parcel delivery volume, state space model, structural change, time series analysis, forecast evaluation*